Tablas de direccionamiento directo y tablas hash

Buscar sin recorrer, con pocas o con muchas claves posibles

Carlos A Delgado S

Pontificia Universidad Javeriana Cali

Octubre 2026

Objetivos de aprendizaje I

Al finalizar esta sesión, el estudiante podrá

- Definir el TAD Diccionario e implementarlo con una tabla de direccionamiento directo, con el costo en tiempo y en espacio de cada operación (OA1, OA2, OA3).
- Reconocer cuándo el universo de claves hace inviable la tabla directa (OA1).
- Calcular la casilla de una clave entera o de una cadena con el método de la división y reconocer cuándo dos claves chocan (OA2).
- Insertar, buscar y eliminar a mano y en C++ en una tabla hash con encadenamiento (OA2, OA3).
- Dar el costo de cada operación en función del factor de carga $\alpha = n/m$ y escoger el número de casillas m (OA1, OA5).

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

¿Quién entró al laboratorio? I

Problema

En la puerta de un laboratorio se registra a cada estudiante que entra, con un código entre 0 y 999 y su nombre. Durante el día llegan miles de preguntas: ¿entró el 412? Y a veces se retira un registro. ¿Cómo se responde cada pregunta sin revisar todos los registros?

¿Entendimos el problema? I

Entradas

Tres clases de orden: registrar un código con un nombre, preguntar por un código y retirar un código. Un código no se registra dos veces; si llega otra vez, cambia el nombre.

Salida

Por cada pregunta, el nombre registrado con ese código o `no esta`.

Con códigos de 0 a 9

Se registran 3 Ana, 7 Luis y 0 Eva. Se pregunta por el 7 y por el 5, se retira el 3 y se pregunta por el 3.

Pregunta

¿Qué se imprime en cada una de las tres preguntas?

¿Entendimos el problema? II

Orden	Registrados	Imprime
registrar 3 Ana	3 Ana	
registrar 7 Luis	3 Ana, 7 Luis	
registrar 0 Eva	3 Ana, 7 Luis, 0 Eva	
preguntar 7		`buscar(7): Luis`
preguntar 5		`buscar(5): no esta`
retirar 3	7 Luis, 0 Eva	
preguntar 3		`buscar(3): no esta`

El 3 estuvo registrado, pero se retiró antes de la pregunta.

Primera idea: una lista I

Los registros en una `list`, en orden de llegada. Preguntar camina desde el comienzo hasta encontrar el código.

```
// Theta(n) en el peor caso: camina hasta encontrar la clave o hasta
↪  el final
list<Registro>::iterator buscar(list<Registro> &l, int clave) {
  list<Registro>::iterator it = l.begin();
  while (it != l.end() && it->clave != clave) {
    ++it;
  }
  return it;
}
```



`buscar(5)`: tres pasos y no está

Primera idea: una lista II

Operación	Tiempo	Por qué
registrar	$\Theta(1)$	`push_back`, si no se revisa que el código ya esté
preguntar	$\Theta(n)$ en el peor caso	camina nodo a nodo; un código que no está recorre los n
retirar	$\Theta(n)$ en el peor caso	buscar el nodo; `erase` ya es $\Theta(1)$

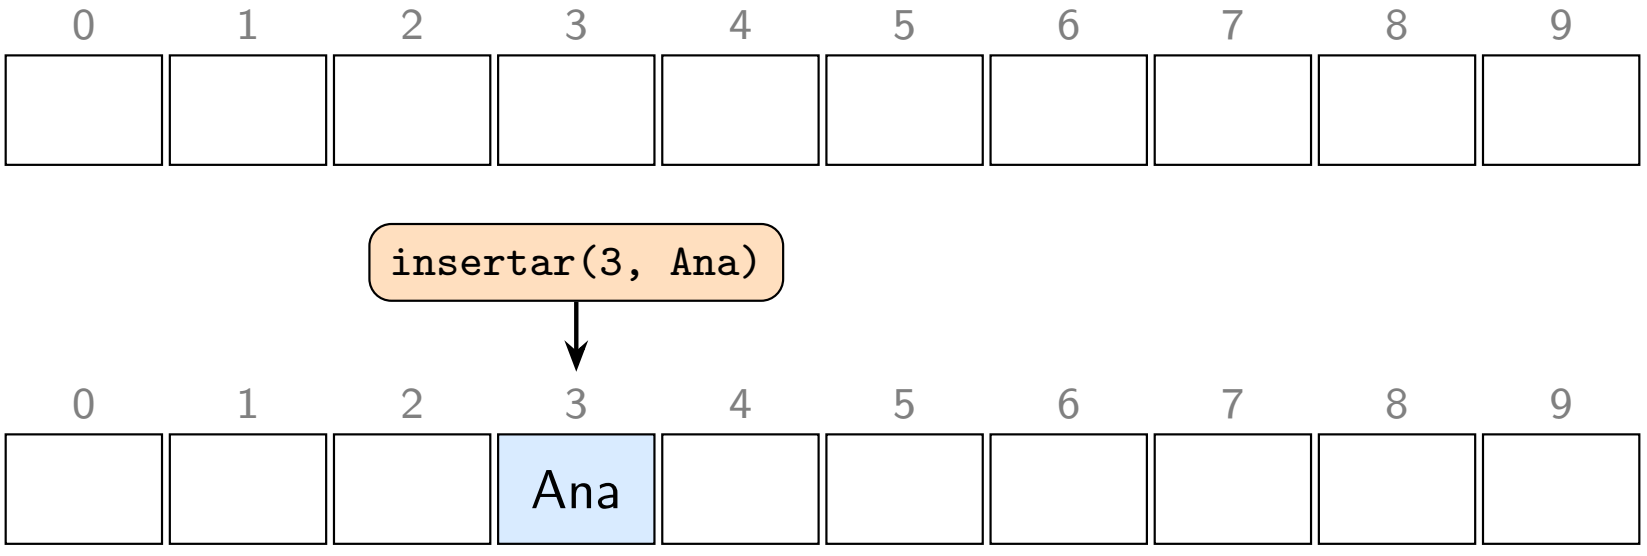
Con 800 registrados y 10 000 preguntas por códigos que no están, se recorren 8 000 000 nodos. El espacio es $\Theta(n)$.

Pregunta

El código ya es un número entre 0 y 999. ¿Hace falta buscarlo, o puede decir él mismo dónde está guardado?

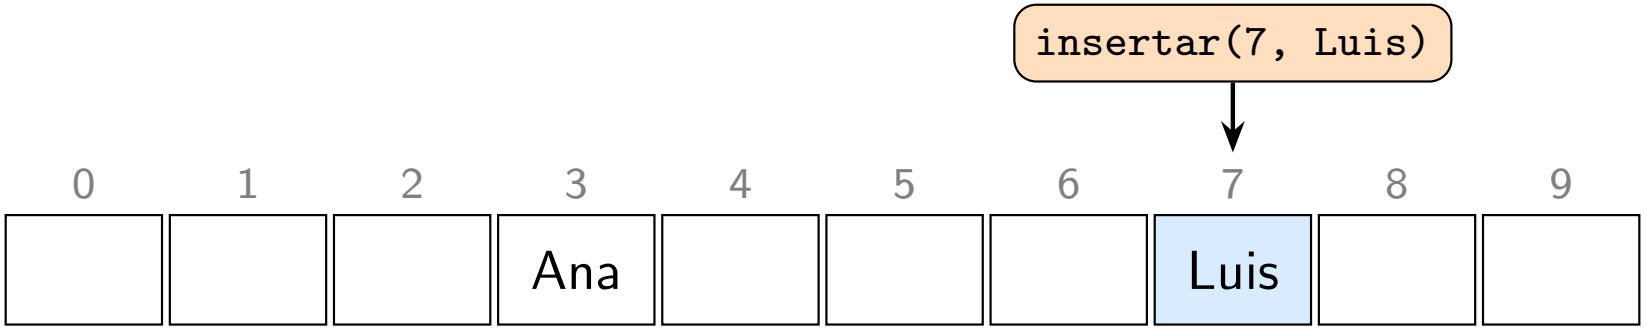
La clave dice la casilla I

Un arreglo con una casilla por cada código posible: el registro del código k va en la casilla k. Con códigos de 0 a 9, diez casillas, todas vacías al comenzar.

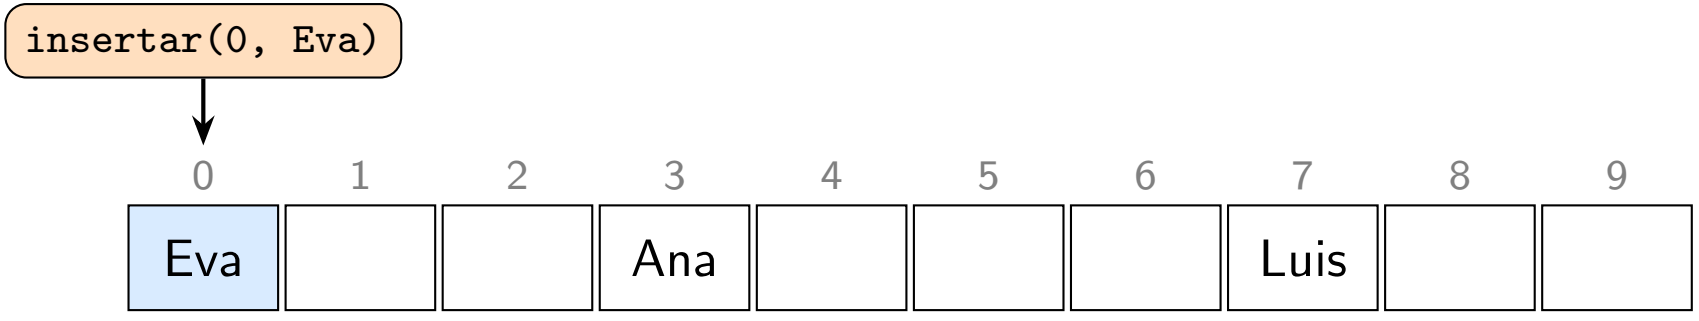


`insertar(3, Ana)`: la clave es 3, así que se escribe en la casilla 3. No se mira ninguna otra.

La clave dice la casilla II



`insertar(7, Luis)`: casilla 7.



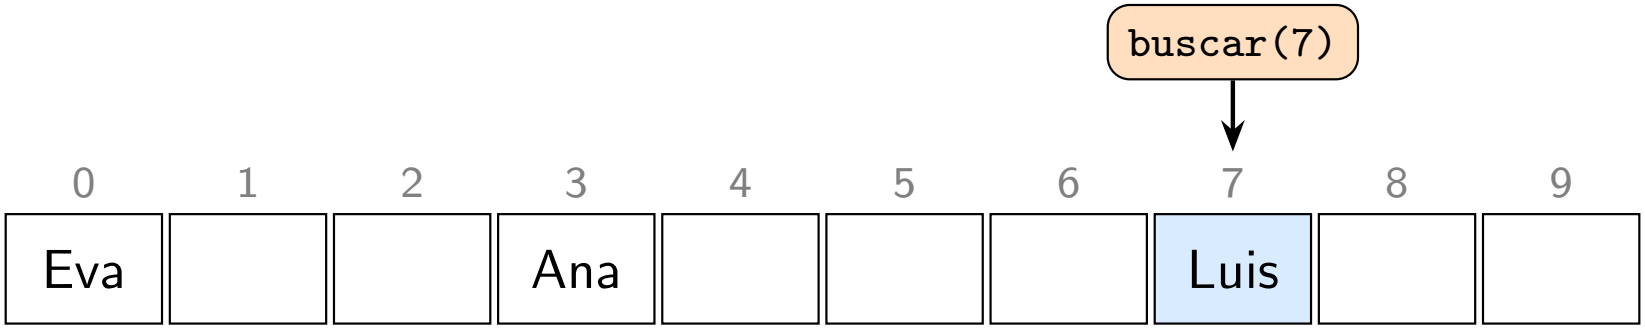
`insertar(0, Eva)`: casilla 0. El orden de llegada no importa; cada clave tiene su sitio.

La clave dice la casilla III

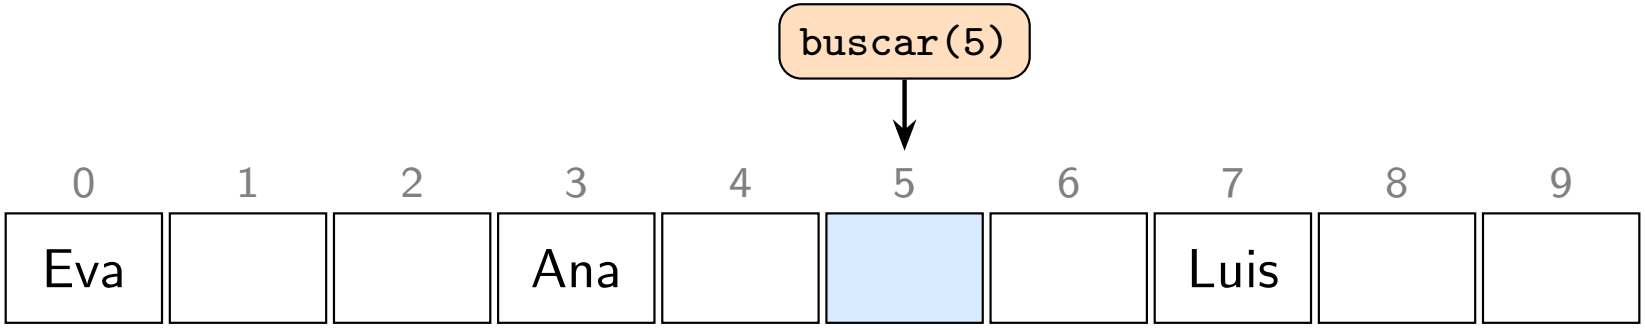
Pregunta

¿Cuántas casillas se leen para responder `buscar(7)`? ¿Y `buscar(5)`?

La clave dice la casilla IV

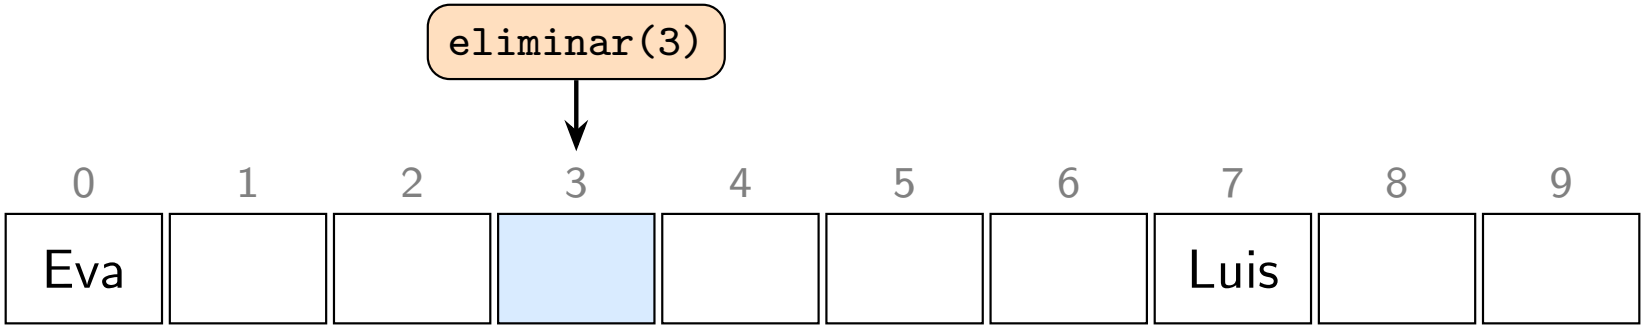


`buscar(7)`: una casilla, la 7, y ahí está Luis.



`buscar(5)`: también una sola. La casilla 5 está vacía, así que el 5 no está registrado, y no hace falta mirar las demás.

La clave dice la casilla V



`eliminar(3)`: se vacía la casilla 3. Después, `buscar(3)` lee esa casilla y dice que no está.

Ninguna operación miró más de una casilla, y ninguna dependió de cuántos registros había.

El TAD Diccionario I

Diccionario (CLRS, introducción del capítulo 11)

Un conjunto dinámico de elementos, cada uno con una *clave* y datos que la acompañan, con tres operaciones:

- `insertar(x)`: agrega el elemento `x`.
- `buscar(k)`: devuelve el elemento de clave `k`, o `NULL` si no hay.
- `eliminar(k)`: quita el elemento de clave `k`.

Tabla de direccionamiento directo (CLRS, §11.1)

Las claves salen de un universo $U = \{0, 1, \ldots, m-1\}$, con m no muy grande, y dos elementos no tienen la misma clave. La tabla es un arreglo $T[0..m-1]$: la casilla k apunta al elemento de clave k, o vale `NULL` si no hay ninguno.

En el laboratorio, U son los códigos de 0 a 999 y $m = 1000$; el elemento es un registro con código y nombre.

El diseño en pseudocódigo I

Las tres operaciones (CLRS, §11.1)

```
buscar(T, k)
   devolver T[k]
insertar(T, x)
   T[x.clave] ← x
eliminar(T, k)
   T[k] ← NULL
```

Cada una calcula una dirección y lee o escribe una casilla. No hay ciclo ni comparación de claves.

Lo que la tabla supone

- Toda clave está entre 0 y $m - 1$. Una clave fuera de ese rango escribe fuera del arreglo.
- Las claves no se repiten: con dos registros de clave 3, el segundo ocupa la casilla del primero.

TablaDirecta en C++ I

Un arreglo de punteros a `Registro` pedido con `new`, todos en `NULL` al comenzar.

```
struct Registro {
  int clave;
  char nombre[20];
};

class TablaDirecta {
private:
  Registro **T;       // T[k] apunta al registro de clave k, o vale
  ↪  NULL
  int m;              // tamano del universo de claves

public:
```

TablaDirecta en C++ II

```
// Theta(m): todas las casillas empiezan vacias
TablaDirecta(int tam) {
  m = tam;
  T = new Registro*[m];
  int k = 0;
  while (k < m) {
    T[k] = NULL;
    k = k + 1;
  }
}
```

TablaDirecta en C++ III

```
// Theta(m): se revisan todas las casillas
~TablaDirecta() {
  int k = 0;
  while (k < m) {
    delete T[k];
    k = k + 1;
  }
  delete[] T;
}

// exige 0 <= clave < m; si la clave ya estaba, cambia el nombre
void insertar(int clave, const char *nombre) {
  assert(clave >= 0 && clave < m);
  if (T[clave] == NULL) {
    T[clave] = new Registro;
    T[clave]->clave = clave;
  }
  strcpy(T[clave]->nombre, nombre);
}
```

TablaDirecta en C++ IV

```
// exige 0 <= clave < m; devuelve NULL si no hay registro
Registro *buscar(int clave) {
  assert(clave >= 0 && clave < m);
  return T[clave];
}

// exige 0 <= clave < m
void eliminar(int clave) {
  assert(clave >= 0 && clave < m);
  delete T[clave];
  T[clave] = NULL;
}
```

- La tabla es dueña de los registros: `insertar` los pide con `new` y `eliminar` los libera con `delete`. `delete` sobre `NULL` no hace nada, así que eliminar un código que no está es válido.
- `buscar` devuelve el puntero de la casilla: o el registro, o `NULL`.

El laboratorio con la tabla I

```
int main() {
  TablaDirecta t(10);
  t.insertar(3, "Ana");
  t.insertar(7, "Luis");
  t.insertar(0, "Eva");
  t.imprimir();
  consultar(t, 7);
  consultar(t, 5);
  t.eliminar(3);
  consultar(t, 3);
  t.imprimir();
  return 0;
}
```

Los dos `imprimir()` escriben `0:Eva 1:- 2:- 3:Ana 4:- 5:- 6:- 7:Luis 8:- 9:-` y `0:Eva 1:- 2:- 3:- 4:- 5:- 6:- 7:Luis 8:- 9:-`.

El laboratorio con la tabla II

Operación	Casilla	Leídas	Salida
`insertar(3, Ana)`	3	1	
`insertar(7, Luis)`	7	1	
`insertar(0, Eva)`	0	1	
`imprimir()`	todas	10	la tabla, con Ana en la 3
`consultar(7)`	7	1	`buscar(7): Luis`
`consultar(5)`	5	1	`buscar(5): no esta`
`eliminar(3)`	3	1	
`consultar(3)`	3	1	`buscar(3): no esta`
`imprimir()`	todas	10	la tabla, con la 3 vacía

La salida es la misma que la de la lista. Lo que cambia es cuántas casillas se miran: una por operación, salvo `imprimir`, que recorre las m.

Lo que cobra la tabla I

Operación	Tiempo	Por qué
crear la tabla	$\Theta(m)$	cada casilla empieza en `NULL`
`insertar(k, nombre)`	$\Theta(1)$	la clave es la dirección: una casilla y, si está vacía, un `new`
`buscar(k)`	$\Theta(1)$	se lee $T[k]$
`eliminar(k)`	$\Theta(1)$	un `delete` y $T[k] \leftarrow$ `NULL`
`imprimir`, destruir	$\Theta(m)$	recorren todas las casillas, llenas o vacías

Espacio

$\Theta(m)$ punteros, uno por clave *posible*, más $\Theta(n)$ registros, uno por clave guardada. Como $n \leq m$, el total es $\Theta(m) = \Theta(|U|)$: lo fija el universo, no lo que se guarda. Con $m = 1000$ y punteros de 8 bytes, la tabla vacía ya ocupa 8 000 bytes.

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

El límite: un universo grande I

Problema

La puerta del laboratorio registra ahora por número de documento, de hasta 10 dígitos. En un día entran 40 personas.

Pregunta

Con la tabla directa, ¿cuánto ocupa la tabla?

El límite: un universo grande II

Con punteros de 8 bytes

Una tabla de $m = 1000$ casillas ocupa 8 000 bytes. Con documentos de 10 dígitos, $m = 10^{10}$ y la tabla ocupa $8 \cdot 10^{10}$ bytes.

- Ochenta mil millones de bytes, 80 GB, para guardar 40 registros: se usarían 40 casillas de 10^{10}.
- Crear la tabla cuesta $\Theta(m)$: poner 10^{10} casillas en `NULL` antes de la primera pregunta.

¿Entendimos el problema? I

Entradas

Los n documentos registrados y una lista de consultas.

Salidas

`si` o `no` por cada consulta.

Con tres documentos registrados, 8920104417, 8920104452 y 8920103990:

Consulta	Respuesta
8920104452	`si`
8920104400	`no`
8920103990	`si`

Pregunta

La lista ocupa poco y la tabla directa busca rápido. ¿Alguna de las dos sirve aquí?

¿Entendimos el problema? II

	Buscar	Espacio	Sirve cuando
Lista enlazada	$\Theta(n)$	$\Theta(n)$	n es pequeño
Tabla directa	$\Theta(1)$	$\Theta(\|U\|)$, con $\|U\| = 10^{10}$	$\|U\|$ es pequeño
Lo que se quiere	cerca de $\Theta(1)$	cerca de $\Theta(n)$	n y $\|U\|$ son grandes

- Con la lista, q consultas por documentos que no están recorren $q \cdot n$ nodos.
- Con la tabla directa, casi todas las casillas quedan vacías.

Pregunta

¿Se puede tener una tabla de pocas casillas para un universo enorme?

Una tabla de 100 casillas I

Tanteo

Se toma una tabla de 100 casillas y cada documento va a la casilla que dicen sus dos últimos dígitos.

Documento	Casilla
8920104417	17
8920104452	52
8920103990	90

Buscar 8920104452 es mirar la casilla 52: un acceso, como en la tabla directa, con 100 casillas en lugar de 10^{10}.

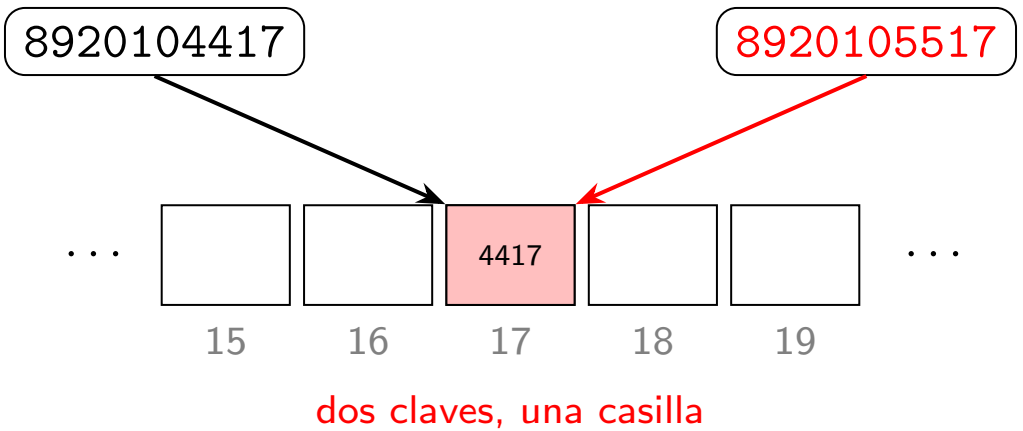
Pregunta

Entra 8920105517. ¿A qué casilla va?

Una tabla de 100 casillas II

Choque

A la 17, que ya tiene a 8920104417. Dos documentos distintos piden la misma casilla, y la casilla solo guarda uno.



- Hay 10^{10} documentos posibles y 100 casillas: a cada casilla le corresponden 10^8 documentos. Ninguna regla para escoger la casilla evita los choques; lo que se puede hacer es repartirlos bien y saber qué hacer cuando ocurren.

Función hash y colisión I

Definición (CLRS, §11.2)

Una *función hash* $h : U \to \{0, 1, \ldots, m-1\}$ asigna a cada clave del universo U una casilla de una tabla $T[0..m-1]$. La clave k se guarda en $T[h(k)]$, y $h(k)$ es el *valor hash* de k. Dos claves distintas con el mismo valor hash forman una *colisión*.

En el tanteo

U son los documentos de 10 dígitos, $m = 100$ y $h(k)$ son los dos últimos dígitos de k. 8920104417 y 8920105517 colisionan en la casilla 17.

- Si $|U| > m$, dos claves del universo comparten casilla: las colisiones no se pueden evitar del todo.

El método de la división I

Definición (CLRS, §11.3)

$h(k) = k$ mód m: la casilla es el residuo de dividir la clave entre el número de casillas. Los dos últimos dígitos son k mód 100.

Pregunta

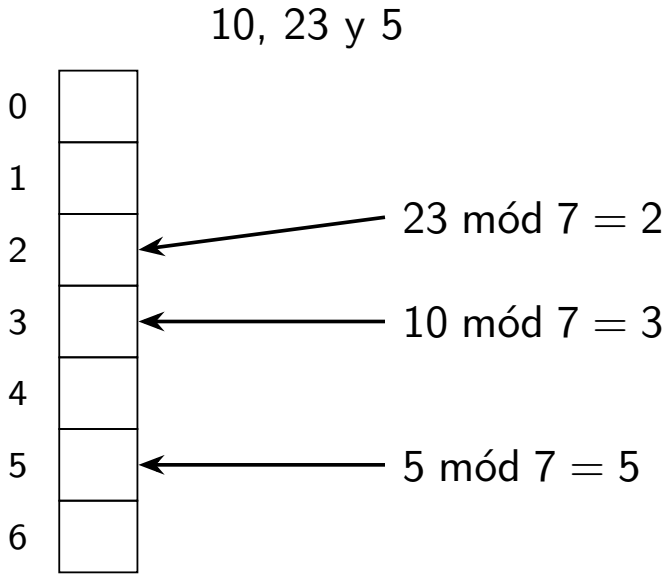
Con $m = 7$, ¿a qué casilla va cada clave?

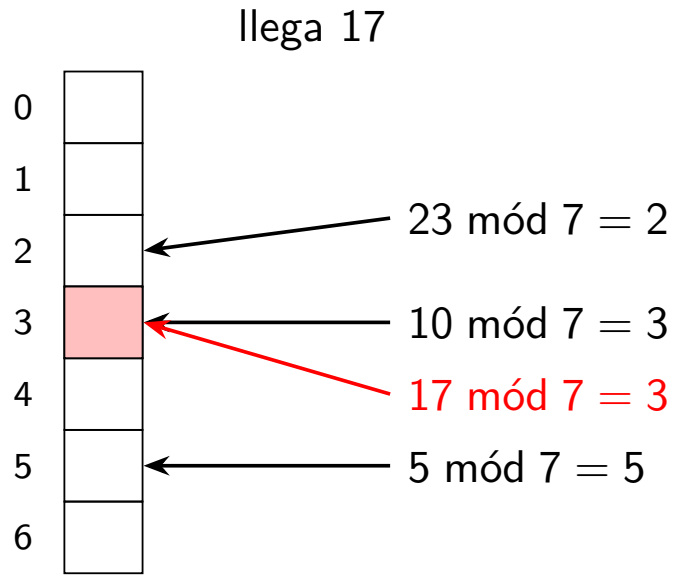
k	k mód 7	$h(k)$
10		
23		
5		
17		

El método de la división II

k	k mód 7	$h(k)$
10	$10 = 1 \cdot 7 + 3$	3
23	$23 = 3 \cdot 7 + 2$	2
5	$5 = 0 \cdot 7 + 5$	5
17	$17 = 2 \cdot 7 + 3$	3

El método de la división III





- 10 y 17 colisionan en la casilla 3.
- Calcular $h(k)$ es una división: $\Theta(1)$.
- En C++, `k % m` da el residuo solo si $k \geq 0$. Con claves negativas hay que tener cuidado, y aparece en el problema del juez.

Claves que son palabras I

Problema

Para contar palabras de un texto, la clave es una cadena. Hay que convertirla en un número antes de tomar el residuo.

Primer intento: sumar los códigos de los caracteres

En C, cada `char` es un número: `'s'` es 115, `'o'` es 111, `'l'` es 108. Con $m = 13$: $115 + 111 + 108 = 334$ y 334 mód $13 = 9$.

Pregunta

¿A qué casilla va `los`?

Claves que son palabras II

También a la 9

`los` tiene los mismos caracteres en otro orden y la suma no ve el orden. Toda palabra choca con sus anagramas: `gato` y `toga`, `amor` y `roma`.

Leer la cadena como un número en base b

Así como $417 = (4 \cdot 10 + 1) \cdot 10 + 7$, la cadena $c_0 c_1 \cdots c_{L-1}$ se lee como $(\cdots((c_0 \cdot b + c_1) \cdot b + c_2) \cdots) \cdot b + c_{L-1}$, y la casilla es ese número módulo m (CLRS, §11.3). Cada carácter pesa distinto según su posición. Aquí $b = 31$.

El polinomio, paso a paso I

Con $b = 31$ y $m = 13$, se reduce módulo 13 en cada paso:

Paso	Carácter	Código	$h \leftarrow (h \cdot 31 + c)$ mód 13
0			$h = 0$
1	`s`	115	$(0 \cdot 31 + 115)$ mód $13 = 11$
2	`o`	111	$(11 \cdot 31 + 111)$ mód $13 = 452$ mód $13 = 10$
3	`l`	108	$(10 \cdot 31 + 108)$ mód $13 = 418$ mód $13 = 2$

Pregunta

¿Por qué reducir en cada paso y no al final?

El polinomio, paso a paso II

- Sin reducir, el número crece como 31^L. Con `'a'` $= 97$, una palabra de seis letras ya pasa de $97 \cdot 31^5 \approx 2{,}8 \cdot 10^9$, y un `int` llega hasta $2^{31} - 1 \approx 2{,}1 \cdot 10^9$. Reduciendo, $h < m$ siempre, y el residuo da el mismo resultado al final.

```
// Lee la cadena como un numero en base 31 (Horner), reduciendo en
↪  cada paso.
int hashPolinomio(const char *s, int m) {
  int h = 0;
  int i = 0;
  while (s[i] != '\0') {
    h = (h * 31 + s[i]) % m;
    i = i + 1;
  }
  return h;
}
```

El polinomio, paso a paso III

El programa calcula las dos funciones con $m = 13$:

Palabra	Suma	Polinomio
`sol`	9	2
`los`	9	3
`gato`	11	1
`toga`	11	12

- Con el polinomio los anagramas se separan. Otras palabras pueden chocar: con 13 casillas, es inevitable.
- Calcular el valor hash de una cadena de L caracteres cuesta $\Theta(L)$: una vuelta por carácter.

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

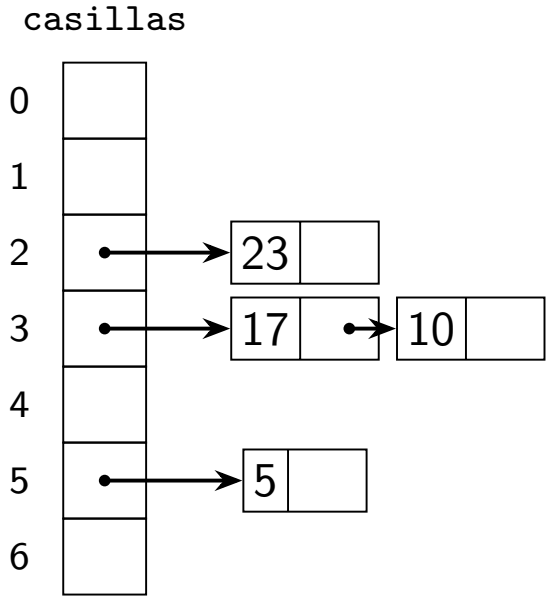
5 Para el juez

6 Ejercicios

Una lista enlazada en cada casilla I

Encadenamiento (CLRS, §11.2)

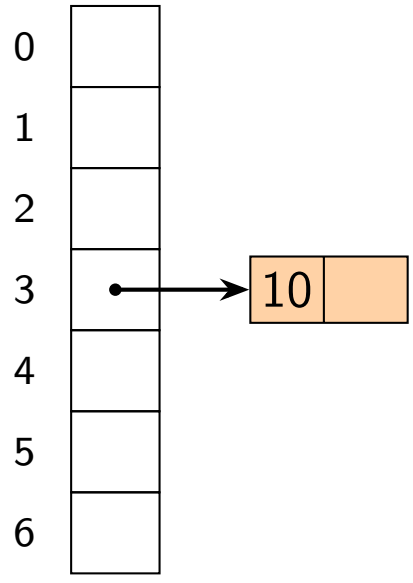
Cada casilla $T[i]$ guarda la cabeza de una lista enlazada con todas las claves k tales que $h(k) = i$. Una casilla sin claves guarda `NULL`. Las colisiones se resuelven en la lista.



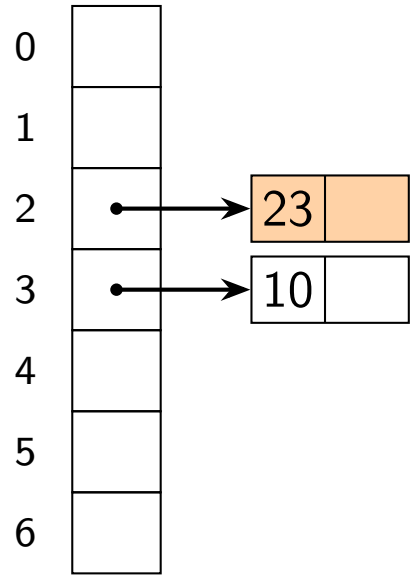
Las claves 10, 23, 5 y 17 con $m = 7$: 10 y 17 comparten la lista de la casilla 3. Cada nodo es el de la lista enlazada simple: la clave y el puntero al siguiente.

Paso a paso: 10, 23, 5, 17, 12, 31 con $m = 7$ I

insertar 10: $h(10) = 3$



insertar 23: $h(23) = 2$

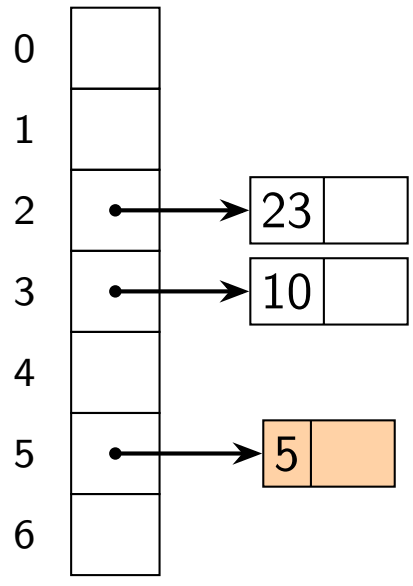


Pregunta

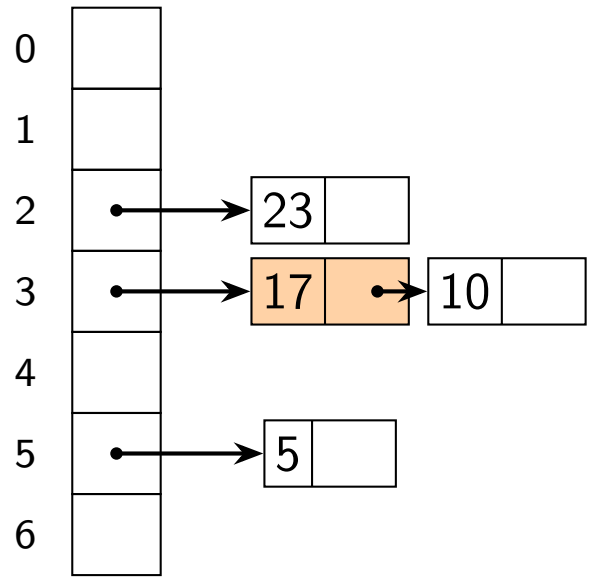
Después de insertar 5, llega 17 y $h(17) = 3$. ¿Va al frente de la lista de la casilla 3 o al final?

Paso a paso: 10, 23, 5, 17, 12, 31 con $m = 7$ II

insertar 5: $h(5) = 5$



insertar 17: $h(17) = 3$

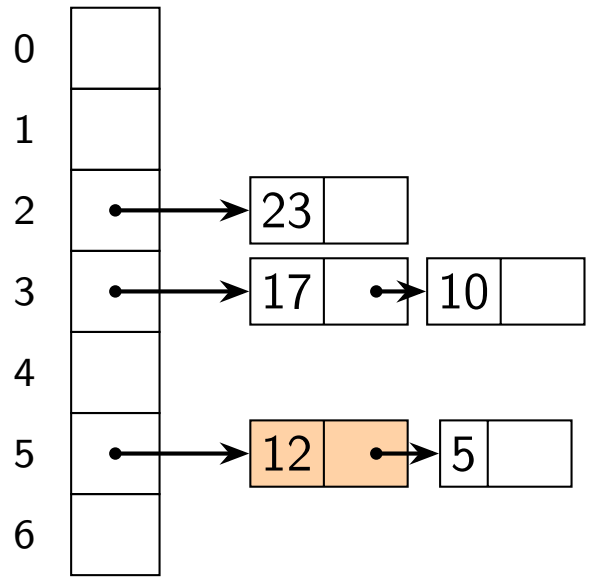


Al frente

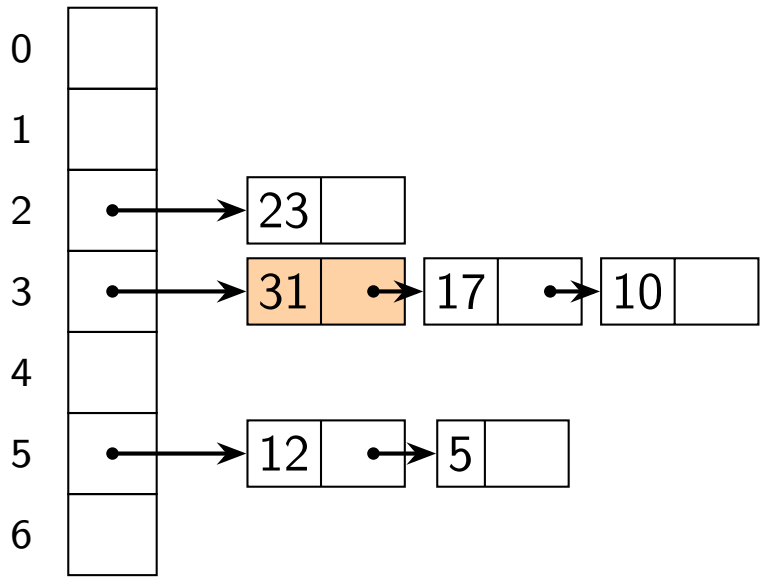
El 17 se cuelga antes del 10: el nuevo nodo apunta a la cabeza vieja y la casilla apunta al nuevo nodo. Son dos punteros, sin importar el largo de la lista. Ir al final pediría recorrerla.

Paso a paso: 10, 23, 5, 17, 12, 31 con $m = 7$ III

insertar 12: $h(12) = 5$



insertar 31: $h(31) = 3$



Paso a paso: 10, 23, 5, 17, 12, 31 con $m = 7$ IV

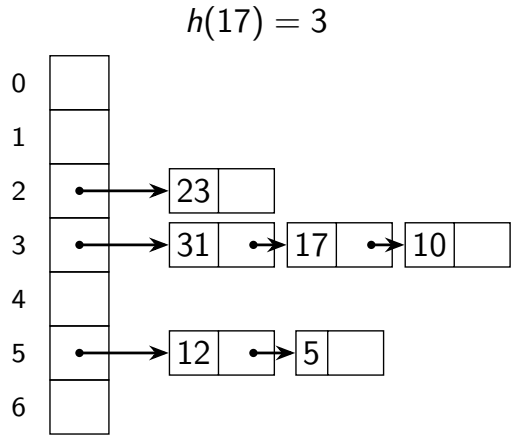
Lo que pasó en cada inserción:

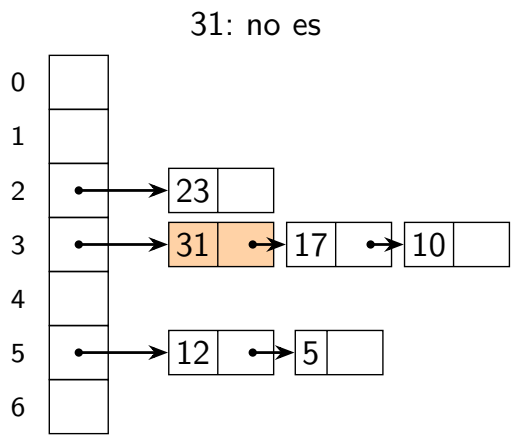
Clave	$h(k)$	Largo de su lista	Casillas vacías
10	3	1	6
23	2	1	5
5	5	1	4
17	3	2	4
12	5	2	4
31	3	3	4

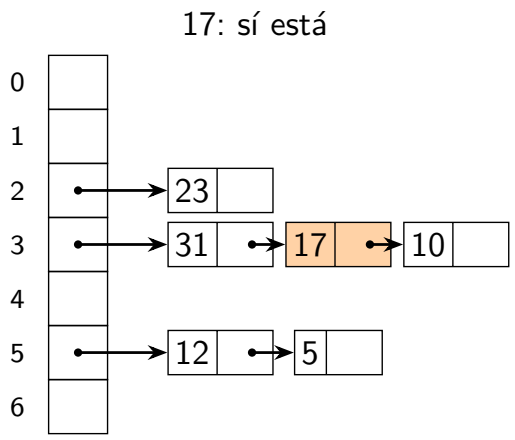
Buscar I

Pregunta

Buscar 17. ¿Qué lista se recorre y con cuántas claves se compara?







Buscar 17

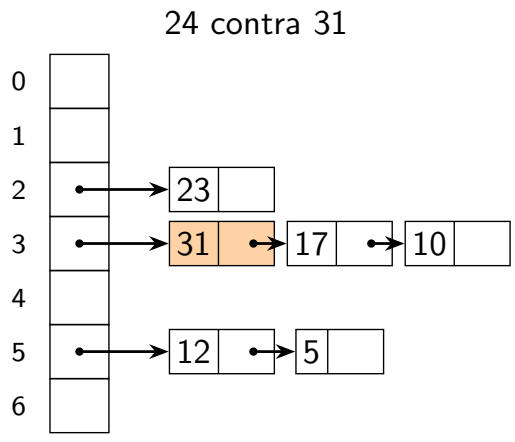
$h(17) = 3$. Se recorre la lista de la casilla 3: 31 no es, 17 sí. Dos comparaciones. Las listas de las casillas 2 y 5 no se miran.

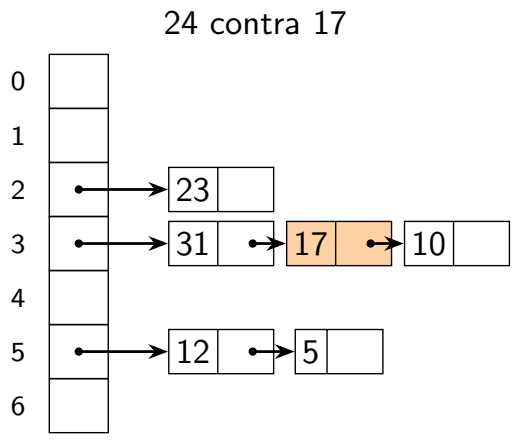
Buscar II

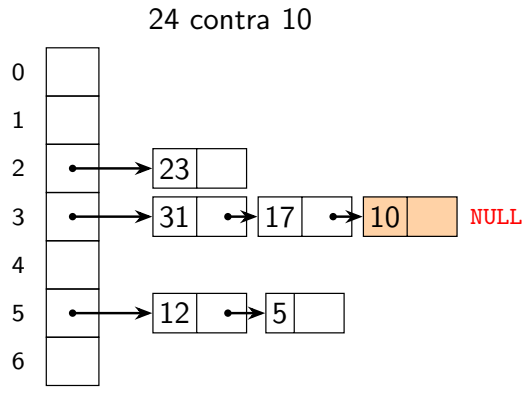
Pregunta

Buscar 24. ¿En qué casilla se busca y cuándo se sabe que no está?

Buscar III







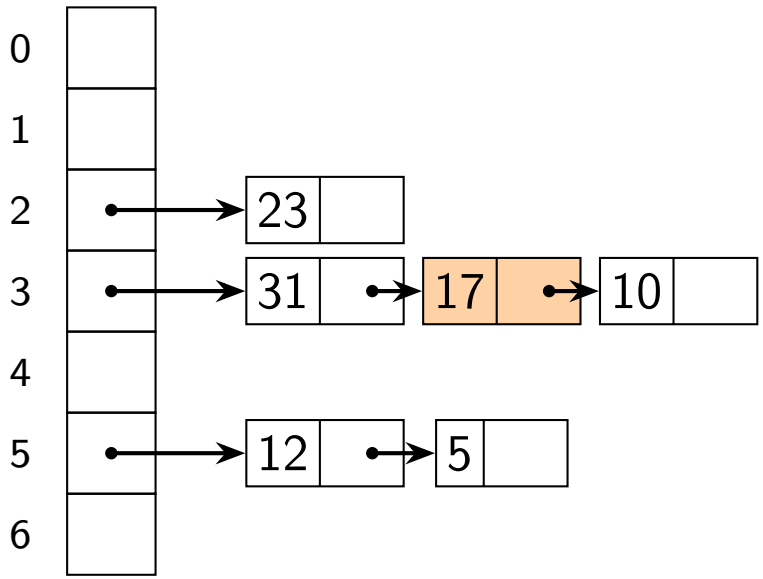
Buscar 24

$h(24) = 24$ mód $7 = 3$. Se compara con 31, 17 y 10, y se llega a `NULL`: 24 no está. Tres comparaciones, el largo entero de la lista.

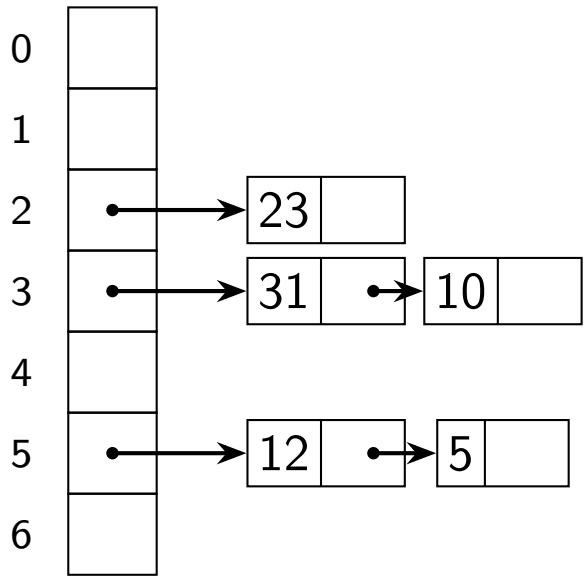
- Una búsqueda que falla recorre la lista completa de su casilla; una que acierta se detiene en la clave. El costo depende del largo de una lista, no del total de claves de la tabla.

Eliminar I

antes: `anterior` en 31



después de eliminar 17



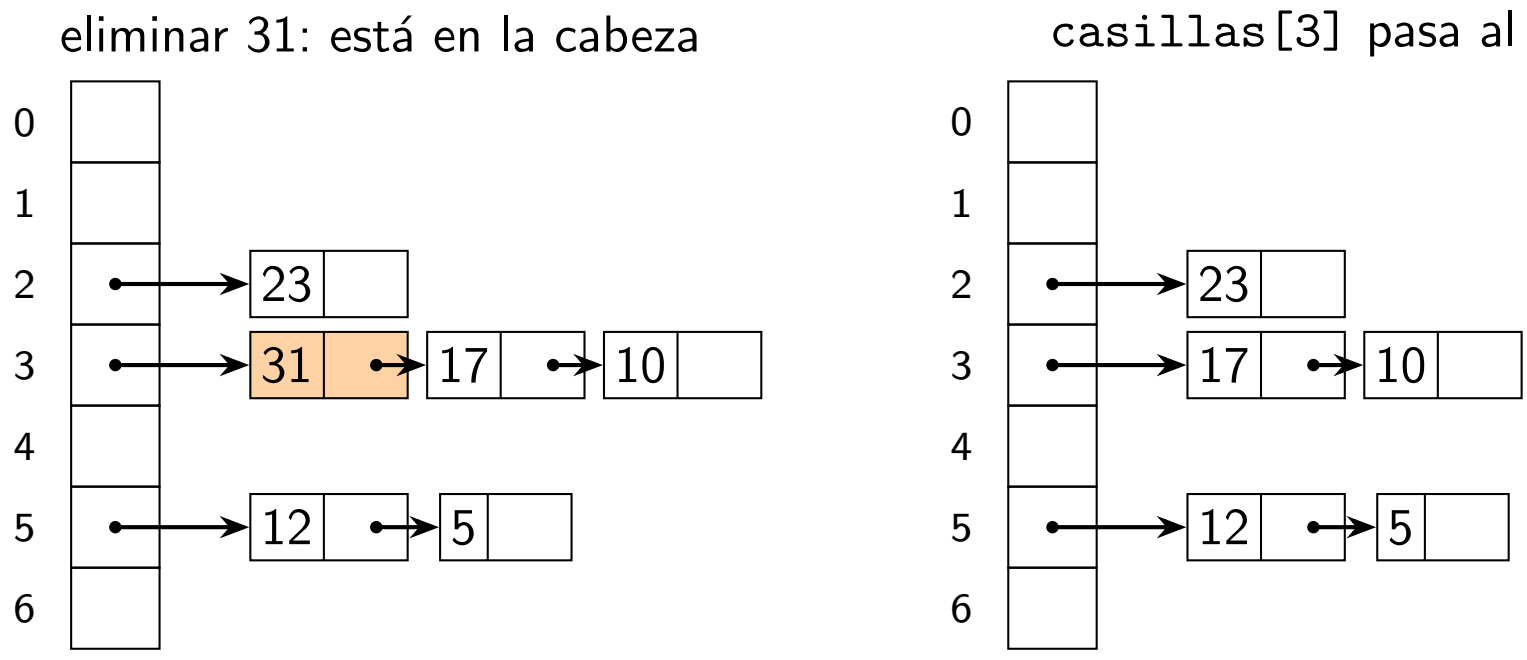
Eliminar II

Eliminar 17 es eliminar en la lista enlazada: se recorre la lista de la casilla 3 con dos punteros, `anterior` y `actual`. Cuando `actual` llega al 17, el `siguiente` de 31 pasa a ser el 10 y el nodo del 17 se libera con `delete`.

Caso límite

Si la clave está en la cabeza, no hay `anterior`: la casilla misma pasa a apuntar al segundo nodo. Eliminar 31 deja `casillas[3]` en el 17.

Eliminar III



Eliminar recorre la lista de su casilla hasta la clave: $\Theta(1+\alpha)$ en promedio. Desenlazar, en la cabeza o en medio, son dos punteros.

La tabla en C++ I

```
struct Nodo {
  int clave;
  Nodo *siguiente;
};

class TablaHash {
private:
  Nodo **casillas;  // cabeza de la lista de cada casilla
  int m;            // numero de casillas
  int n;            // numero de claves guardadas

  // Metodo de la division. Exige k >= 0.
  int h(int k) {
    return k % m;
  }
```

La tabla en C++ II

```
public:
  TablaHash(int tam) {
    m = tam;
    n = 0;
    casillas = new Nodo *[m];
    int i = 0;
    while (i < m) {
      casillas[i] = NULL;
      i = i + 1;
    }
  }
```

El constructor deja las m cabezas en `NULL`: $\Theta(m)$.

La tabla en C++ III

```
// Recorre la lista de h(k) hasta hallar k o llegar a NULL.
bool buscar(int k) {
  Nodo *actual = casillas[h(k)];
  while (actual != NULL && actual->clave != k) {
    actual = actual->siguiente;
  }
  return actual != NULL;
}
```

```
// Cuelga k al frente de su lista. Exige que k no este.
void insertar(int k) {
  int i = h(k);
  Nodo *nuevo = new Nodo;
  nuevo->clave = k;
  nuevo->siguiente = casillas[i];
  casillas[i] = nuevo;
  n = n + 1;
}
```

La tabla en C++ IV

```
// Desenlaza el nodo de k. Devuelve si lo encontro.
bool eliminar(int k) {
  int i = h(k);
  Nodo *anterior = NULL;
  Nodo *actual = casillas[i];
  while (actual != NULL && actual->clave != k) {
    anterior = actual;
    actual = actual->siguiente;
  }
  bool estaba = actual != NULL;
  if (estaba) {
    if (anterior == NULL) {
      casillas[i] = actual->siguiente;
    } else {
      anterior->siguiente = actual->siguiente;
    }
    delete actual;
    n = n - 1;
  }
  return estaba;
}
```

La tabla en C++ V

```
~TablaHash() {
  int i = 0;
  while (i < m) {
    while (casillas[i] != NULL) {
      Nodo *muerto = casillas[i];
      casillas[i] = casillas[i]->siguiente;
      delete muerto;
    }
    i = i + 1;
  }
  delete[] casillas;
}
```

- El destructor libera nodo por nodo cada lista y después el arreglo de cabezas: cada `new` tiene su `delete` y el `new[]` su `delete[]`.
- `insertar` no revisa si la clave ya está. Si las claves pueden repetirse, se llama a `buscar` antes.

El ejemplo, corriendo I

Un `main` crea `TablaHash t(7)`, inserta 10, 23, 5, 17, 12 y 31 imprimiendo $h(k)$, imprime la tabla, busca 17 y 24, elimina 17 y pide el largo de la casilla 3.

Salida

`h(10) = 3`, `h(23) = 2`, `h(5) = 5`, `h(17) = 3`, `h(12) = 5`, `h(31) = 3`, y la tabla:

```
0:  1:  2: 23  3: 31 17 10  4:  5: 12 5  6:
```

Después, `buscar 17: 1`, `buscar 24: 0`, `eliminar 17: 1`, `largo de la casilla 3: 2` y `n = 5, m = 7`.

Las listas salen como en los dibujos: la última clave insertada en cada casilla queda de primera.

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

El factor de carga I

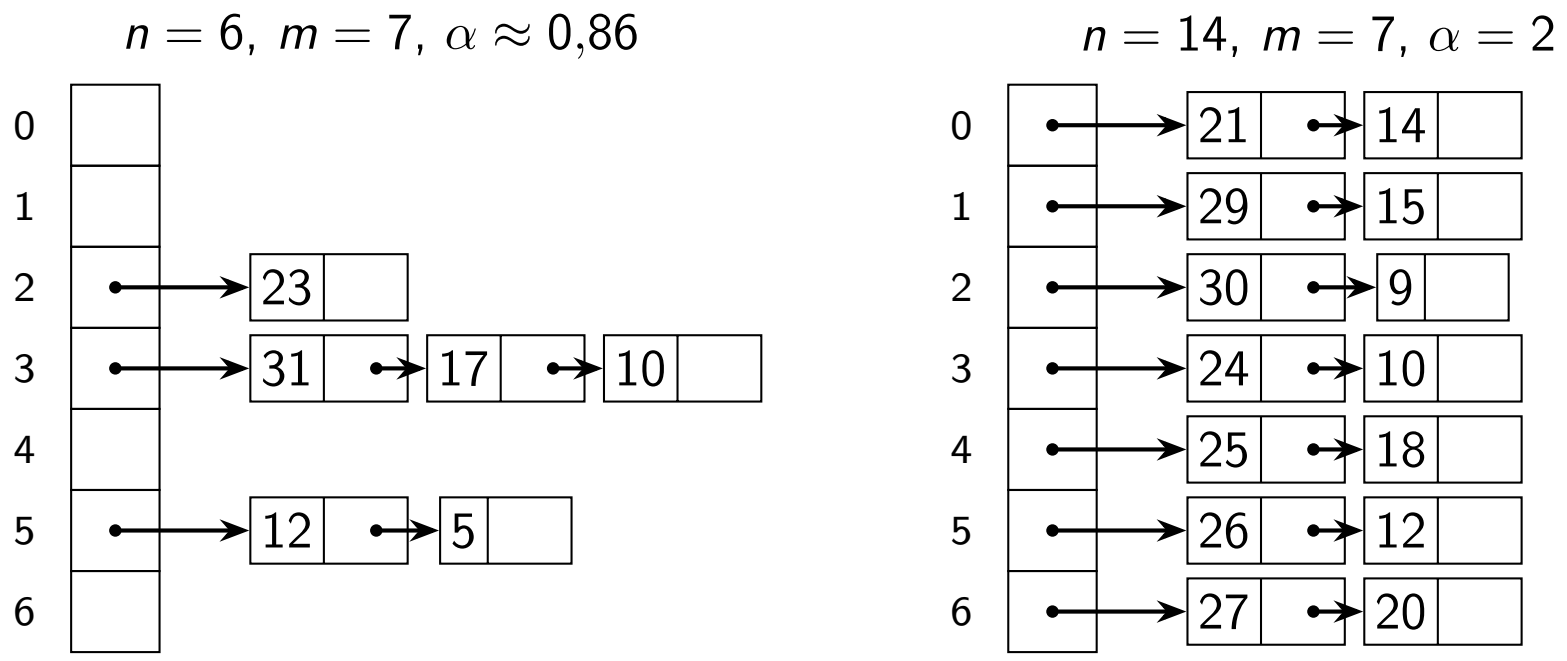
Definición (CLRS, §11.2)

Con n claves en una tabla de m casillas, el *factor de carga* es $\alpha = n/m$: el largo promedio de las listas.

En el ejemplo

Con las seis claves, $\alpha = 6/7 \approx 0{,}86$. Las listas miden 0, 0, 1, 3, 0, 2 y 0: suman 6, y su promedio es $6/7$. Tras eliminar 17, $\alpha = 5/7 \approx 0{,}71$.

El factor de carga II



A la izquierda, listas de 0, 0, 1, 3, 0, 2 y 0: promedio 6/7. A la derecha la tabla está llena y bien repartida: cada lista mide exactamente $\alpha = 2$, y α puede pasar de 1.

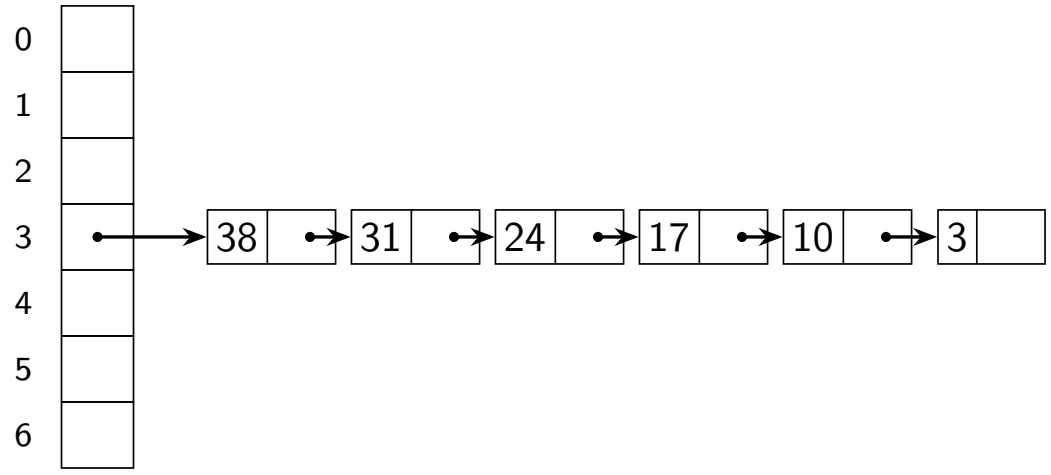
El factor de carga III

Pregunta

α es el promedio. ¿Cuánto puede medir la lista más larga?

El peor caso: todas a la misma casilla I

Las claves 3, 10, 17, 24, 31 y 38 con $m = 7$: todas dejan residuo 3.



- Seis casillas vacías y una lista con las $n = 6$ claves. α sigue siendo $6/7$.
- Buscar 45, con $h(45) = 3$, compara con las seis antes de llegar a `NULL`. La tabla se comporta como la lista enlazada del comienzo: buscar y eliminar cuestan $\Theta(n)$.
- Insertar al frente sigue costando $\Theta(1)$.

El caso promedio I

Hashing uniforme independiente (CLRS, §11.2)

Se supone que cada clave cae en cualquiera de las m casillas con la misma probabilidad, sin importar dónde cayeron las demás.

- Con ese supuesto, la lista de una casilla mide en promedio α. Una búsqueda que falla recorre una lista entera; una que acierta, en promedio, cerca de la mitad de una lista más el nodo de la clave.
- CLRS (teoremas 11.1 y 11.2) concluye que las dos cuestan, en promedio, $\Theta(1+\alpha)$: el 1 es calcular $h(k)$ y llegar a la casilla, y α es el recorrido.

Pregunta

Si n crece y m se deja fijo, ¿qué pasa con $1+\alpha$? ¿Y si m crece al mismo ritmo que n?

El caso promedio II

- Con m fijo, $\alpha = n/m$ crece con n y buscar vuelve a ser lineal, solo que m veces más rápido que la lista.
- Con m proporcional a n, por ejemplo $m \geq n/2$, se tiene $\alpha \leq 2$ y $1 + \alpha \leq 3$: buscar y eliminar cuestan $O(1)$ en promedio.

Lo que cobra la tabla hash con encadenamiento I

Operación	Promedio	Peor caso	Por qué
$h(k)$, clave entera	$\Theta(1)$	$\Theta(1)$	una división
$h(s)$, cadena de L	$\Theta(L)$	$\Theta(L)$	una vuelta por carácter
`insertar(k)`	$\Theta(1)$	$\Theta(1)$	se cuelga al frente de su lista
`buscar(k)`	$\Theta(1+\alpha)$	$\Theta(n)$	se recorre una lista; en el peor caso, todas las claves están en ella
insertar sin repetir	$\Theta(1+\alpha)$	$\Theta(n)$	primero se busca
`eliminar(k)`	$\Theta(1+\alpha)$	$\Theta(n)$	se busca con `anterior`; desenlazar es $\Theta(1)$
`largo(i)`	$\Theta(1+\alpha)$	$\Theta(n)$	se cuentan los nodos de una lista
`imprimir`, destructor	$\Theta(m+n)$	$\Theta(m+n)$	se visitan las m casillas y los n nodos
constructor	$\Theta(m)$	$\Theta(m)$	m cabezas en `NULL`

Lo que cobra la tabla hash con encadenamiento II

Espacio

$\Theta(m+n)$: el arreglo de m cabezas y un nodo por clave, con la clave y un puntero. Ninguna operación pide memoria aparte que crezca con n.

	Buscar, promedio	Buscar, peor caso	Espacio
Lista enlazada	$\Theta(n)$	$\Theta(n)$	$\Theta(n)$
Tabla directa	$\Theta(1)$	$\Theta(1)$	$\Theta(\|U\|)$
Tabla hash, m proporcional a n	$O(1)$	$\Theta(n)$	$\Theta(n)$

Escoger m I

Pregunta

Se insertan las 1000 claves $4, 8, 12, \ldots, 4000$ en una tabla de $m = 64$ casillas. $\alpha = 1000/64 \approx 15{,}6$. ¿Cuánto mide la lista más larga?

Escoger m II

Un programa inserta $k = paso \cdot i$ con $i = 1, \ldots, 1000$ y mide cada lista con `largo`:

m	paso	Casillas vacías	Lista más larga	α
64	1	0	16	15,6
64	4	48	63	15,6
61	4	0	17	16,4
61	61	60	1000	16,4

Escoger m III

- $64 = 2^6$, y k mód 2^6 son los últimos 6 bits de k. Un múltiplo de 4 termina en 00: solo quedan 16 casillas posibles, las múltiplos de 4, y las otras 48 nunca se usan. Las listas miden cuatro veces α.
- Con el primo 61 los múltiplos de 4 recorren todos los residuos: ninguna casilla vacía y listas de 16 o 17.
- Ningún m resiste un patrón hecho a su medida: con paso 61, las 1000 claves caen en la casilla 0 de la tabla de 61.

Regla (CLRS, §11.3)

Con el método de la división se escoge un primo que no esté cerca de una potencia de 2. Una potencia de 2 o de 10 usa solo los últimos bits o los últimos dígitos de la clave, como la tabla de 100 casillas con los documentos.

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

Para el juez: UVa 484, The Department of Redundancy Department I

UVa 484, The Department of Redundancy Department,
`https://vjudge.net/problem/UVA-484`
Envío: `https://vjudge.net/problem/UVA-484`

Qué pide

La entrada es una secuencia de enteros positivos, negativos o cero, tan larga como se quiera, hasta el fin del archivo. Por cada entero distinto se imprime una línea con el entero y cuántas veces apareció, en el orden en que apareció por primera vez.

¿Entendimos el problema?

Con 3 1 2 2 1 3 5 3 3 2 sale 3 4, 1 2, 2 3 y 5 1. El 3 va primero porque fue el primero en llegar, no porque sea el que más se repite.

Para el juez: UVa 484, The Department of Redundancy Department II

Cómo atacarlo con una tabla hash

Una tabla hash con encadenamiento cuyo nodo guarda la clave y un contador. Por cada número se busca en su lista: si está, se suma uno; si no, se cuelga un nodo con cuenta 1 y el número se anota en un arreglo de claves en orden de llegada. Al final se recorre ese arreglo y se busca la cuenta de cada una. Con $m = 100\,003$, primo, cada número cuesta $\Theta(1 + \alpha)$ en promedio.

Las trampas

- Los negativos: en C++, `-7 % 5` da -2. Con `k % m` como casilla, un negativo escribe fuera del arreglo. La casilla es `((k % m) + m) % m`.
- No se sabe cuántos números vienen, así que no hay n para dimensionar: m se fija grande desde el comienzo.
- $-100\,003$, 0 y $100\,003$ caen en la misma casilla y son claves distintas: la lista compara la clave, no la casilla.

Contenido I

1 TAD tabla de direccionamiento directo

2 Pocas claves, universo enorme: la función hash

3 Encadenamiento

4 Lo que cuesta

5 Para el juez

6 Ejercicios

Ejercicio en parejas: a mano I

Inserten, en este orden, 22, 5, 16, 38, 27, 49 y 3 en una tabla con encadenamiento de $m = 11$ casillas, colgando al frente.

Las preguntas

1. Dibujen la tabla. ¿Cuánto vale α y cuánto mide la lista más larga?
2. ¿Cuántas comparaciones hace buscar 60?
3. Repitan con $m = 10$. ¿Qué tabla queda mejor repartida, y por qué no es la del primo?

Ejercicio en parejas: a mano II

Lo que debe salir

1. Con $m = 11$: 22 va a la casilla 0, 3 a la 3, y 5, 16, 38, 27 y 49 a la 5, con la lista `49 27 38 16 5`. $\alpha = 7/11 \approx 0{,}64$ y la lista más larga mide 5.
2. 60 mód 11 = 5: cinco comparaciones y `NULL`. No está.
3. Con $m = 10$ cada clave va a su propia casilla: 2, 5, 6, 8, 7, 9 y 3. Las claves 5, 16, 27, 38 y 49 van de 11 en 11, un patrón hecho a la medida de $m = 11$. El primo protege contra los patrones comunes, no contra todos.

Ejercicio en parejas: dos que suman x I

Dado un arreglo de n enteros no negativos y un número x, decir si hay dos casillas distintas cuyos valores suman x.

Las preguntas

1. Con $a = \langle 8, 3, 11, 6, 2, 15 \rangle$, ¿qué responde con $x = 9$, $x = 21$ y $x = 12$?
2. ¿Cuánto cuesta probar todas las parejas?
3. Al llegar a $a[i]$, ¿qué número habría que haber visto antes? ¿Qué estructura responde eso rápido?

Ejercicio en parejas: dos que suman x II

Lo que debe salir

1. $x = 9$: sí, $3 + 6$. $x = 21$: sí, $6 + 15$. $x = 12$: no; $6 + 6$ no cuenta, porque hay un solo 6. El programa imprime `1`, `1` y `0`.
2. Todas las parejas son $n(n-1)/2$: $\Theta(n^2)$.
3. $x - a[i]$. Se busca en la tabla de los ya vistos y después se guarda $a[i]$. Buscar antes de guardar es lo que impide usar el 6 dos veces. Son n búsquedas e inserciones de $\Theta(1 + \alpha)$ en promedio: $\Theta(n)$ con m proporcional a n, más $\Theta(n)$ de espacio aparte.

Propuestos para la casa: tabla directa I

1. **Conjunto de banderas.** Implemente un conjunto de enteros de 0 a $m-1$ con un arreglo de `bool`: `agregar`, `quitar`, `pertenece`, `unir` e `intersecar`. Dé el costo de cada una.

2. **¿Hay repetidos?** Dado un arreglo de n enteros, todos entre 0 y 999, diga si algún valor aparece dos veces. Escriba la versión que compara cada par y la que usa una tabla de 1000 casillas, y compare sus costos con $\langle 412, 87, 903, 15, 87, 230\rangle$ y con $\langle 5, 999, 0, 314\rangle$.

3. **Un universo que no empieza en 0.** Los códigos del laboratorio van ahora de 1000 a 1999. Escriba `buscar` e `insertar` con una tabla de 1000 casillas. Después, los códigos válidos son solo los pares entre 0 y 1998: ¿cuántas casillas hacen falta, y qué cuenta convierte un código en su casilla?

Propuestos para la casa: tablas hash I

4. **Distintos.** Escriba una función que cuente cuántos valores distintos hay en un arreglo de n enteros no negativos con la tabla hash. ¿Cuánto cuesta? ¿Y ordenando primero?

5. **Tabla de palabras.** Cambie la clave de `TablaHash` a una cadena de hasta 20 letras, con `hashPolinomio` como h. ¿Qué cambia en `buscar`?

6. **El peor caso a la medida.** Para $m = 13$, escriba ocho claves que caigan todas en la casilla 4, y cuente cuántas comparaciones hace buscar una clave que no está.

7. **Repartir documentos.** Genere 2000 documentos de 10 dígitos que comparten los seis primeros y mida, con `largo`, la lista más larga y las casillas vacías con $m = 100$, $m = 128$ y $m = 101$.

8. **Eliminar con la lista doble.** Si cada casilla fuera una lista doblemente enlazada y se tuviera el nodo en la mano, ¿cuánto costaría eliminar?

Propuesto para el juez: UVa 442 I

UVa 442, Matrix Chain Multiplication,
`https://vjudge.net/problem/UVA-442`
Envío: `https://vjudge.net/problem/UVA-442`

Qué pide

Hasta 26 matrices, cada una con una letra, y expresiones con paréntesis completos, como `(A(BC))`. Multiplicar $p \times q$ por $q \times r$ cuesta $p \cdot q \cdot r$. Por cada expresión, el total o `error`.

Cómo atacarlo

Las dimensiones van en una tabla directa de 26 casillas, la de la letra c en `c - 'A'`: leerla cuesta $\Theta(1)$. La expresión se recorre con una pila: una letra apila su matriz y un `)` saca dos y apila el producto. $\Theta(L)$ por expresión.

La trampa

El primero que sale de la pila es la matriz de la *derecha*.

Pistas para los propuestos I

1. Las tres primeras leen o escriben una casilla, $\Theta(1)$; unir e intersecar recorren las m casillas con `||` y `&&`, $\Theta(m)$.
2. La casilla v guarda una bandera: si ya apareció el valor v. Comparar cada par es $\Theta(n^2)$ en el peor caso; la tabla cuesta $O(n+m)$ con $m = 1000$, y $\Theta(m)$ de espacio aparte.
3. Restar 1000 deja las claves entre 0 y 999. Con los pares, la cuenta que se busca también es una sola operación.
4. Se busca cada valor y, si no estaba, se inserta y se suma uno. $\Theta(n)$ en promedio con m proporcional a n; ordenando, $\Theta(n \log n)$ y un recorrido que compara vecinos.
5. El nodo guarda un arreglo de `char`; la comparación `actual->clave != k` pasa a ser `strcmp`, y cada comparación cuesta lo que la cadena.
6. Sirve cualquier clave $4 + 13j$. Buscar una que no está recorre las ocho.
7. Con 100 casillas solo cuentan los dos últimos dígitos, y con 128, los últimos 7 bits. Compare con el primo.
8. Con `anterior` en cada nodo no hay que buscar al de antes: desenlazar es $\Theta(1)$ (CLRS, §11.2).

Resumen I

- El TAD Diccionario tiene `insertar`, `buscar` y `eliminar`. Con claves en $U = \{0, \ldots, m-1\}$, la tabla de direccionamiento directo las hace en $\Theta(1)$: la clave es la casilla. Ocupa $\Theta(|U|)$ aunque guarde pocos elementos.
- Una función hash lleva cada clave a una de m casillas. Con el método de la división, $h(k) = k$ mód m; una cadena se lee como un número en base 31, reduciendo en cada paso.
- Las colisiones son inevitables cuando el universo es mayor que la tabla. Con encadenamiento, cada casilla es la cabeza de una lista enlazada: insertar al frente cuesta $\Theta(1)$, y buscar y eliminar recorren una sola lista.
- Con $\alpha = n/m$, buscar y eliminar cuestan $\Theta(1 + \alpha)$ en promedio y $\Theta(n)$ en el peor caso. El espacio es $\Theta(m + n)$.
- m se escoge primo y lejos de una potencia de 2: con $m = 64$ y claves múltiplos de 4, 48 casillas quedaron vacías.

Lo que sigue

El contenedor `map` de la biblioteca, que guarda pares de clave y valor, y problemas que se resuelven con él.

Referencias I



T. H. Cormen, C. E. Leiserson, R. L. Rivest y C. Stein. *Introduction to Algorithms*, 4.ª ed. MIT Press, 2022. Capítulo 11, tablas hash: introducción, operaciones de diccionario; §11.1 tablas de direccionamiento directo; §11.2 tablas hash, encadenamiento y su análisis; §11.3 funciones hash, método de la división.



R. Thareja. *Data Structures Using C*. Oxford University Press, 2018. Capítulo 15, *Hashing and Collision*: §15.2 tablas hash; §15.4.1 método de la división; §15.5.2 resolución de colisiones por encadenamiento.



UVa Online Judge. Problema 484, *The Department of Redundancy Department*: `https://vjudge.net/problem/UVA-484`.



UVa Online Judge. Problema 442, *Matrix Chain Multiplication*: `https://vjudge.net/problem/UVA-442`.